

# EM算法(Expectation-Maximum)

## 原理篇

- **本质**：概率模型，去估计一个密度函数，**最大化对数似然函数**去估计参数。无法直接用极大化对数似然函数得到模型分布的参数，用**启发式迭代法**，用于求解含有隐变量的最大似然估计、最大后验概率估计问题。

1. 隐变量：对概率模型有一定的影响，但无法观测；

观测数据X+隐变量 = 完全数据

2. 无法用**极大似然**的两种情况：数据缺失、含有未知隐变量

- **作用**：经常存在数据缺失或者不可用的问题，这时候直接处理数据比较困难，而**数据添加**办法有很多种，常用的有神经网络拟合、添补法、卡尔曼滤波法等等，但是EM算法之所以能迅速普及主要源于它**算法简单**，**稳定上升**的步骤能非常可靠地找到“最优的收敛值”。
- **目标**：是使包含隐变量的数据集的后验概率或似然函数最大化，进而得到最优的参数估计
- **思想**：我们可以发现我们的算法里已知的是**观察数据**，未知的是隐含数据和模型参数，在**E步**，我们所做的事情是固定模型参数的值，优化隐含数据的分布，而在**M步**，我们所做的事情是固定隐含数据分布，优化模型参数的值。

### 主要步骤：

已知：概率分布、随机抽取的样本；

未知：分类、模型参数

- E-step：**猜想隐含数据**，更新隐含数据和模型参数
- M-step：**基于观察数据和猜想的隐含数据求极大对数似然**，求解模型K
- E-step：基于前面得到的模型K，继续猜测隐含数据，继续极大化对数似然
- M-step：求模型参数
- 直至模型分布无明显变化，算法收敛

EM算法步骤如下：

输入：观测变量数据X，隐变量Z，联合分布 $p(X, Z | \Theta)$

输出：模型参数 $\Theta$

(1) 选择初始参数 $\Theta_0$

(2) E步：记 $\Theta_i$ 为第i次迭代参数 $\Theta$ 的估计值，在第i+1次迭代的E步，计算 $Q(\Theta, \Theta_i)$ ;

(3) M步：确定第i+1次迭代的参数的估计值 $\Theta_{i+1}$ ，即为：

$$\Theta^{(i+1)} = \operatorname{argmax}_{\Theta} Q(\Theta, \Theta^{(i)})$$

(4) 重复(2)和(3)步，直至收敛

## EM算法的引入篇

有三枚硬币A、B、C

三枚硬币的模型：

$$\begin{aligned} p(y|\theta) &= \sum_z P(y, z|\theta) = \sum_z p(z|\theta)p(y|z, \theta) \\ &= \pi p^y (1-p)^{1-y} + (1-\pi) q^y (1-q)^{1-y} \end{aligned}$$

N枚硬币的模型：

$$\begin{aligned} P(Y|\Theta) &= \sum_z P(Z|\Theta)P(Y|Z, \Theta) \\ &= \prod_{j=1}^n [\pi p^{y_j} (1-p)^{1-y_j} + (1-\pi) q^{y_j} (1-q)^{1-y_j}] \end{aligned}$$

求模型的参数  $\Theta = (\pi, p, q)$  的极大似然估计，即目标函数为：

$$\Theta = \operatorname{argmax}_{\log} P(Y|\Theta) = \operatorname{argmax}_{\log} \sum_z P(Y|Z, \Theta) p(Z, \Theta)$$

面对含隐变量的概率模型，目标是极大化观测数据（不完全数据）Y关于参数 $\Theta$ 的对数似然函数，即极大化(取对数方便计算)：

$$\begin{aligned} L(\Theta) &= \log P(Y|\Theta) = \log \sum_z P(Y, Z|\Theta) \\ &= \log \left( \sum_z P(Y|Z, \Theta) P(Z|\Theta) \right) \end{aligned}$$

EM算法通过迭代逐步近似极大化L( $\theta$ )的 + Jensen不等式

$$\begin{aligned} L(\Theta) - L(\Theta^{(i)}) &= \log \left( \sum_Z P(Y|Z, \Theta) P(Z|\Theta) \right) - \log P(Y|\Theta^{(i)}) \\ &= \log \left[ \sum_Z P(Z|Y, \Theta^{(i)}) \frac{P(Y|Z, \Theta) P(Z|\Theta)}{P(Z|Y, \Theta^{(i)})} \right] - \log P(Y|\Theta^{(i)}) \\ &\quad \text{由 Jensen 不等式 且 } \sum_Z P(Z|Y, \Theta^{(i)}) = 1 \\ &\geq \sum_Z P(Z|Y, \Theta^{(i)}) \log \frac{P(Y|Z, \Theta) P(Z|\Theta)}{P(Z|Y, \Theta^{(i)})} - \frac{\log P(Y|\Theta^{(i)}) * \sum_Z P(Z|Y, \Theta^{(i)})}{\sum_Z P(Z|Y, \Theta^{(i)})} \\ &= \sum_Z P(Z|Y, \Theta^{(i)}) * \log \frac{P(Y|Z, \Theta) P(Z|\Theta)}{P(Z|Y, \Theta^{(i)}) P(Y|\Theta^{(i)})} \end{aligned}$$

即：

$$\Theta^{(i+1)} = \operatorname{argmax} [L(\Theta^{(i)}) + \sum_Z P(Z|Y, \Theta^{(i)}) * \log \frac{P(Y|Z, \Theta) P(Z|\Theta)}{P(Z|Y, \Theta^{(i)}) P(Y|\Theta^{(i)})}]$$

去掉与 $\Theta$ 无关的变量的式子：

$$\begin{aligned} \Theta^{(i+1)} &= \operatorname{argmax} \left[ \sum_Z P(Z|Y, \Theta^{(i)}) * \log P(Y|Z, \Theta) P(Z|\Theta) \right] \\ &= \operatorname{argmax}_{\Theta} Q(\Theta, \Theta^{(i)}) = E[\log P(Z|Y, \Theta^{(i)})] \dots (1) \end{aligned}$$

观测数据 + 隐变量 = 完全数据

Jensen不等式：

$$\begin{aligned} \log \left( \sum \alpha_i \varphi(x_i) \right) &\geq \sum \alpha_i \log \varphi(x_i) \\ \sum \alpha_i &= 1 \text{ 且 } \alpha_i \geq 0 \end{aligned}$$

# EM算法的收敛性

证明： $P(Y|\theta)$ 为观测数据的似然函数，且是递增的，即：

$$P(Y|\theta^{(i+1)}) \geq P(Y|\theta^{(i)})$$

证明如下：

$$P(Y|\theta) = \frac{P(Y, Z|\theta)}{P(Z|Y, \theta)} \dots \dots \text{有贝叶斯公式展开得}$$

$$\log P(Y|\theta) = \log P(Y, Z|\theta) - \log P(Z|Y, \theta) \dots \text{取对数}$$

$$Q(\theta, \theta^{(i)}) = \sum_z \log P(Y, Z|\theta) P(Z|Y, \theta^{(i)}) \dots \text{由(1)得}$$

构造下式（因为取对数方便相减和相除，同时构造了贝叶斯公式）：

$$H(\theta, \theta^{(i)}) = \sum_z \log P(Z|Y, \theta) P(Z|Y, \theta^{(i)})$$

$$\log P(Y|\theta) = Q(\theta, \theta^{(i)}) - H(\theta, \theta^{(i)}) \dots (2)$$

在式(2)中分别取 $\theta$ 为 $\theta_i$ 和 $\theta_{i+1}$ ，并相减：

$$\begin{aligned} \log P(Y|\theta^{(i+1)}) - \log P(Y|\theta^{(i)}) &= \\ [Q(\theta^{(i+1)}, \theta^{(i)}) - Q(\theta^{(i)}, \theta^{(i)})] &- [H(\theta^{(i+1)}, \theta^{(i)}) - H(\theta^{(i)}, \theta^{(i)})] \end{aligned}$$

其中对H：

$$\begin{aligned} [H(\theta^{(i+1)}, \theta^{(i)}) - H(\theta^{(i)}, \theta^{(i)})] &= \sum_z (\log P(Z|Y, \theta^{(i+1)}) - \log P(Z|Y, \theta^{(i)})) P(Z|Y, \theta^{(i)}) = \\ \sum_z (\log \frac{P(Z|Y, \theta^{(i+1)})}{P(Z|Y, \theta^{(i)})} P(Z|Y, \theta^{(i)})) &\leq \\ \log(\sum_z \frac{P(Z|Y, \theta^{(i+1)})}{P(Z|Y, \theta^{(i)})} P(Z|Y, \theta^{(i)})) \dots \text{Jensen不等式得} \\ \log(\sum_z P(Z|Y, \theta^{(i+1)})) &= \log 1 = 0 \end{aligned}$$

对Q，由于Q的 $i+1$ 项已经达到极大，所以有：


$$[Q(\theta^{(i+1)}, \theta^{(i)}) - Q(\theta^{(i)}, \theta^{(i)})] \geq 0$$

最后证明得到：

$$\log P(Y|\theta^{(i+1)}) \geq \log P(Y|\theta^{(i)})$$

## 应用篇--GMM

EM在GMM中的应用

 高斯分布分析

图中可知：

1. 单个高斯拟合效果差，均值应该分布在数据密集处
2. 混合高斯模型中的**隐变量**，同时，隐变量在概率模型中不能改变边缘分布，即：

$$p(x_i) = \int_{z_i} p(x_i|z_i) * p(z_i) dz_i = \alpha_z = \sum_{z_i=1}^k \alpha_{z_i} N(x_i|\mu_z, \Sigma_z)$$

每个数据都有一个隐变量，告诉你在哪个高斯模型中(由两个高斯扩展到n个高斯)

$$P(z_i = z_1|x_i, \Theta^g) = \frac{a}{a+b}$$

3.

$$P(x) = \sum_{l=1}^k \alpha_l * N(X|\mu_l, \Sigma_l) \quad \sum_{l=1}^k \alpha_l = 1$$

$$\Theta = \{\alpha_1, \dots, \alpha_k, \mu_1, \dots, \mu_k, \Sigma_1, \dots, \Sigma_{k-1}\}$$

4. 目标函数为：

$$\Theta_{MLE} = \operatorname{argmax}_{\Theta} * L(\Theta | X) = \operatorname{argmax}_{\Theta} (\sum_{l=1}^n \log * \sum_{l=1}^k \alpha_l N(X | \mu_l, \Sigma_l))$$

该式子包含和（或积分）的对数，不能像单个高斯模型那样直接求导，再令导数为0来求解。这时我们需要利用 **EM 算法通过迭代逐步近似极大化L(Θ|X)来求解**。

## EM算法在GMM中的应用：

高斯混合模型的概率分布模型如下：

$$P(Y|\theta) = \sum_{K=1}^K \alpha_k \phi(Y|\theta)$$

$$\text{其中：} \sum_{K=1}^K \alpha_k = 1, \theta_k = (\mu_k, \sigma_k^2)$$

$$\theta = (\alpha_1, \alpha_2, \dots, \alpha_k, \theta_1, \theta_2, \dots, \theta_k)$$

$$\phi(Y|\theta) = \frac{1}{\sqrt{2\pi}\sigma_k} \exp(-\frac{(y - \mu_k)^2}{2\sigma_k^2})$$

用  $\gamma$  作为隐变量，去确定是哪个模型， $\gamma=1/0$ 。

完整数据的似然函数为：

$$P(y, \gamma|\theta) = \prod_{j=1}^N P(y_j, \gamma_{j1}, \gamma_{j2}, \dots, \gamma_{jK}|\theta)$$

$$= \prod_{K=1}^K \prod_{j=1}^N [\alpha_k \phi(y_j|\theta_k)]^{\gamma_{jK}}$$

完全数据的对数似然为：

$$\log P(y, \gamma|\theta) = \sum_{K=1}^K [\sum_{j=1}^N \log \alpha_k + \sum_{j=1}^N \gamma_{jk} [\log(\frac{1}{\sqrt{2\pi}}) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2]]$$

## EM算法中的E步：确定Q函数，对每一个隐变量求期望

根据当前模型参数，计算分模型k对观测数据 $y_j$ 的响应度

$$\begin{aligned}
Q(\theta, \theta^{(i)}) &= E[\log P(y, \gamma | \theta) | y, \theta^{(i)}] \\
&= E\left[\sum_{K=1}^K \left[\sum_{j=1}^N \log \alpha_k + \sum_{j=1}^N \gamma_{jk} \left[\log\left(\frac{1}{\sqrt{2\pi}}\right) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2\right]\right]\right] \\
&= \sum_{K=1}^K \left[\sum_{j=1}^N (E_{\gamma_{jk}}) \log \alpha_K + \sum_{j=1}^N (E_{\gamma_{jk}}) \left[\log\left(\frac{1}{\sqrt{2\pi}}\right) - \log \sigma_K - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2\right]\right]
\end{aligned}$$

计算E

$$\begin{aligned}
\gamma_{jk} &= E(\gamma_{jk} | y, \theta) \\
&= P(\gamma_{jk} = 1 | y, \theta) * 1 + P(\gamma_{jk} = 0, \theta) * 0 \\
&= \frac{P(\gamma_{jk} = 1, y_j | \theta)}{P(y_j | \theta)} = \frac{P(\gamma_{jk} = 1, y_j | \theta)}{\sum_{K=1}^K P(\gamma = 1, y_j | \theta)} \\
&= \dots = \frac{\alpha_k \phi(y_j | \theta_k)}{\sum_{K=1}^K \alpha_k \phi(y_j | \theta_k)}
\end{aligned}$$

最终求得Q

$$Q(\theta, \theta^{(i)}) = \sum_{K=1}^K \left[\sum_{j=1}^N \log \alpha_k + \sum_{j=1}^N \gamma_{jk} \left[\log\left(\frac{1}{\sqrt{2\pi}}\right) - \log \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2\right]\right]$$

**M步,进行迭代模型的参数**

$$\begin{aligned}
\theta^{(i+1)} &= \operatorname{argmax}_{\theta} Q(\theta, \theta^{(i)}) \\
\mu_k &= \frac{\sum_{j=1}^N \gamma_{jk} y_j}{\sum_{j=1}^N \gamma_{jk}} \\
\sigma_k^2 &= \frac{\sum_{j=1}^N \gamma_{jk} (y_j - \mu_k)^2}{\sum_{j=1}^N \gamma_{jk}} \\
\alpha_k &= \frac{\sum_{j=1}^N \gamma_{jk}}{N}
\end{aligned}$$

[参考1：知乎关于EM](#)

[参考2：GMM应用](#)

[参考3：EM九个境界](#)

参考4：统计学习方法